

实验报告

- 2253314
- 拓凯文

诗歌生成过程

总体来说，诗歌生成主要是经过数据预处理、模型训练、模型推理三个步骤

- 在数据预处理部分，使用格式为“标题:正文”的纯文本文件作为原始语料。为了保证训练数据的质量，会过滤掉含有特殊字符（如括号、下划线、书名号等）或长度低于 5 字、高于 80 字的诗句。每一首合法诗句都会在开头加上统一的起始标记 `start_token='G'`，在结尾加上结束标记 `end_token='E'`
- 模型主体采用了 LSTM 模型，由三个核心模块组成，词嵌入层、双层 LSTM 递归网络以及线性输出层
- 如果选择训练模型，则会根据定义好的模型进行训练，同时保存权重
- 在生成部分，首先加载已训练好的模型权重，同时模型内部隐状态与细胞状态被初始化为零。模型在每个时间步基于当前输入序列输出下一字符的概率分布，并通过取最大概率选择最可能的字符作为下一个输入，循环迭代直到生成结束标记或达到最大长度

RNN 模型

- RNN：采用循环结构，当前时刻的输出不仅依赖于当前输入，还依赖于前一时刻的隐藏状态
- LSTM：为了解决 RNN 的长期依赖问题，引入了三个门机制
 - 遗忘门：决定丢弃多少旧信息
 - 输入门：决定添加多少新信息
 - 输出门：决定隐藏状态的输出
- GRU：结构更简单，但性能与 LSTM 接近甚至更优，采用两个门机制
 - 更新门：控制当前状态保留多少旧信息
 - 重置门：控制多少旧信息用于生成新信息

修改部分

- 完成了题目要求
- 支持 GPU 训练
- 写了更好的 log 功能，可以绘制 loss 曲线

输出结果

- 训练过程

```
epoch 2 batch number 100 loss is: 5.677567005157471
prediction [10, 74, 4, 6, 45, 0, 25, 339, 36, 74, 21, 1, 6, 21, 25, 44, 29, 0, 6, 16, 77, 59, 62, 1, 6, 64, 9, 24, 45, 0, 26, 62, 4, 108, 262, 1, 4, 239, 9, 26, 29, 0, 4, 179, 19, 103, 134, 1, 3, 3]
b_y      [201, 74, 147, 147, 86, 0, 339, 339, 13, 160, 440, 1, 214, 346, 69, 44, 17, 0, 75, 16, 10, 702, 129, 1, 150, 545, 373, 1414, 303, 0, 228, 67, 1463, 104, 2614, 1, 13, 60, 239, 797, 66, 536, 0, 314, 101, 37, 2018, 299, 1, 3, 3]
*****
epoch 2 batch number 200 loss is: 5.333110332489014
finish save model
prediction [10, 111, 9, 41, 4, 26, 250, 0, 4, 90, 9, 32, 4, 39, 27, 1, 4, 16, 4, 21, 9, 36, 74, 0, 10, 11, 138, 177, 77, 22, 162, 1, 7, 295, 4, 85, 9, 9, 612, 0, 4, 16, 13, 7, 4, 44, 13, 1, 10, 95, 4, 20, 9, 16, 8, 0, 4, 111, 15, 219, 4, 21, 162, 1, 3, 3]
b_y      [1666, 1672, 1030, 294, 475, 1024, 622, 0, 99, 439, 487, 125, 130, 4, 172, 1, 77, 192, 11, 6, 1841, 361, 2338, 0, 264, 5, 7, 17, 704, 384, 279, 1, 66, 87, 2242, 128, 7, 1140, 2167, 284, 0, 84, 1264, 46, 699, 312, 1853, 1720, 1, 581, 451, 145, 132, 88, 57, 73, 0, 31, 912, 373, 798, 170, 4796, 1302, 1, 3, 3]
```

- 输出诗歌

```
(D:\Anaconda_env\python311_torch) PS C:\Us
inital linear weight
D:\Anaconda_env\python311_torch\Lib\site-p
to include dim=X as an argument.
    return self._call_impl(*args, **kwargs)
日已见无光飞。
青山不见无人别。
不得青山路客别。
不得此时愁欲见。
-----
inital linear weight
红草上罗飞。
此时不见山水客。
不知何事来何事，一夜何曾见此生。
不。
-----
inital linear weight
山花落叶。
青草不见人家里。
杨柳杨风乱山路。
一望山中人见路。
不知。
-----
```

inital linear weight
夜至何从事。
皇皇何所为相名在在庭花。
不得青山路客落。
不得杨花落。
不得青山路客落。
不得杨花落。
不得青山路客落。
不得青山路客落。
不得青山路客落。
不得青山路客落。
不得杨花落。

inital linear weight
湖。
落叶带花落花落。
青山一夜来水飞。
一家山树晚，何事于人知。
不。

inital linear weight
君已从此山。
此时不见山水客，何必相见两相寻。
不得相望不相见公子。
